BÀI TẬP LỚN MACHINE LEARNING

Dự đoán khách hàng đăng ký tiền gửi có kỳ hạn

Phân loại Bank Marketing trước cuộc gọi; Test tách khỏi fit, CV có giới hạn

Lợi
Metrics · Mô hình tuyến tính

Trí
Encoding · Random Forest · Biểu đồ

Danh
SVM · Phân tích lỗi

Nhân
Pipeline · Benchmark · Champion

Bài toán: gọi ai trước trong chiến dịch telesale?

Bối cảnh nghiệp vụ

- Ngân hàng gọi telesale mời khách gửi tiền có kỳ hạn
- Mỗi cuộc gọi tốn thời gian và chi phí nhân sự
- Chỉ 47.4% khách trong dữ liệu đồng ý

MỤC TIÊU

Ước lượng P(yes) của từng khách TRƯỚC khi gọi để ưu tiên danh sách gọi

Vì sao chọn Machine Learning?

Tương tác phức tạp

Kết quả phụ thuộc tổ hợp tuổi, số dư, khoản vay, lịch sử liên hệ, tháng — khó viết thành luật

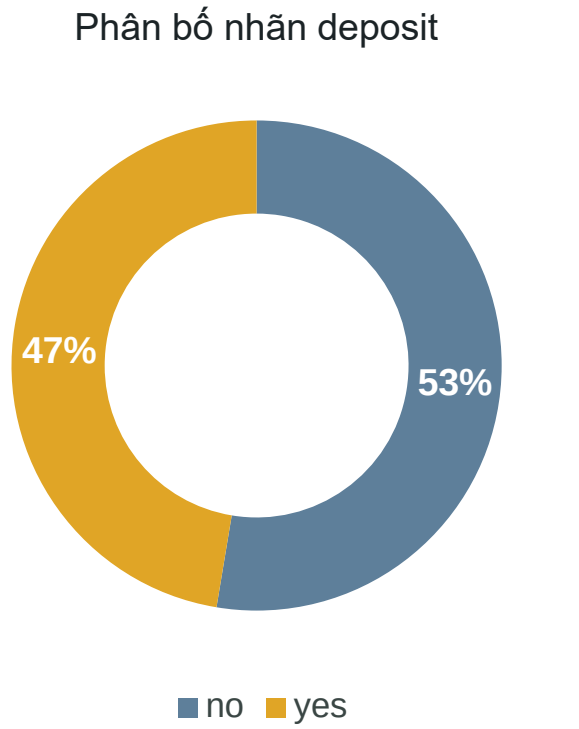
Điều chỉnh được đánh đổi

Đầu ra là xác suất: chọn ngưỡng theo ngân sách cuộc gọi (Precision ↔ Recall)

Học từ dữ liệu lịch sử

11,162 cuộc gọi có nhãn; huấn luyện lại khi có chiến dịch mới

Dữ liệu và bốn thách thức chính



11,162

khách hàng · 16 thuộc tính · nhãn gần cân bằng

Rò rỉ dữ liệu: duration

Thời lượng cuộc gọi chỉ biết sau khi gọi → loại khỏi mô hình

Nhiều giá trị 'unknown'

poutcome 74.6% · contact 21.0% · education 4.5%

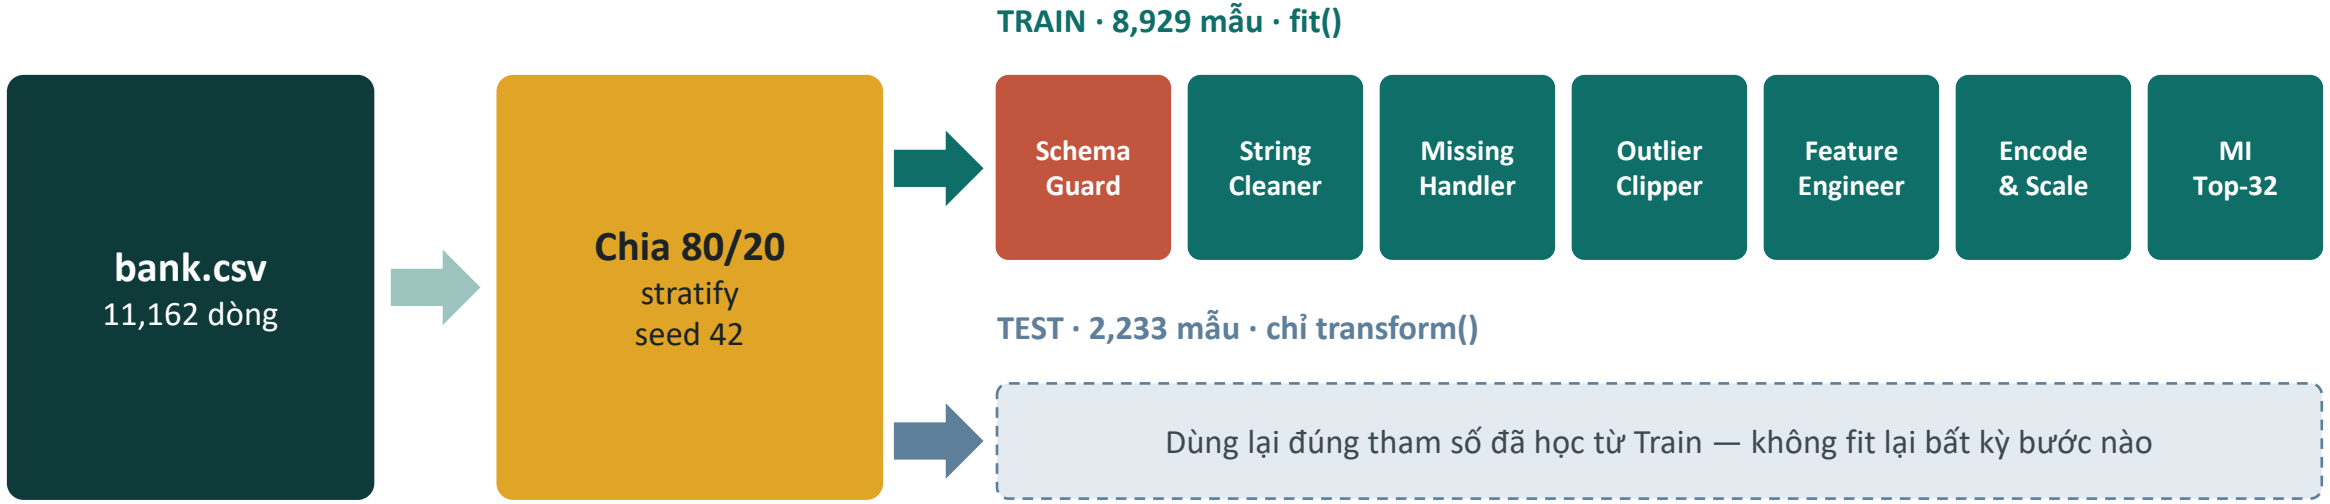
Lệch phải & outlier

balance, campaign, previous có đuôi dài, giá trị cực đoan

Mã đặc biệt pdays = –1

Nghĩa là 'chưa từng liên hệ', không phải một số đo

Pipeline chống rò rỉ dữ liệu



duration bị loại ngay bước 1

Schema Guard xóa cột rò rỉ và từ chối mọi cột lạ

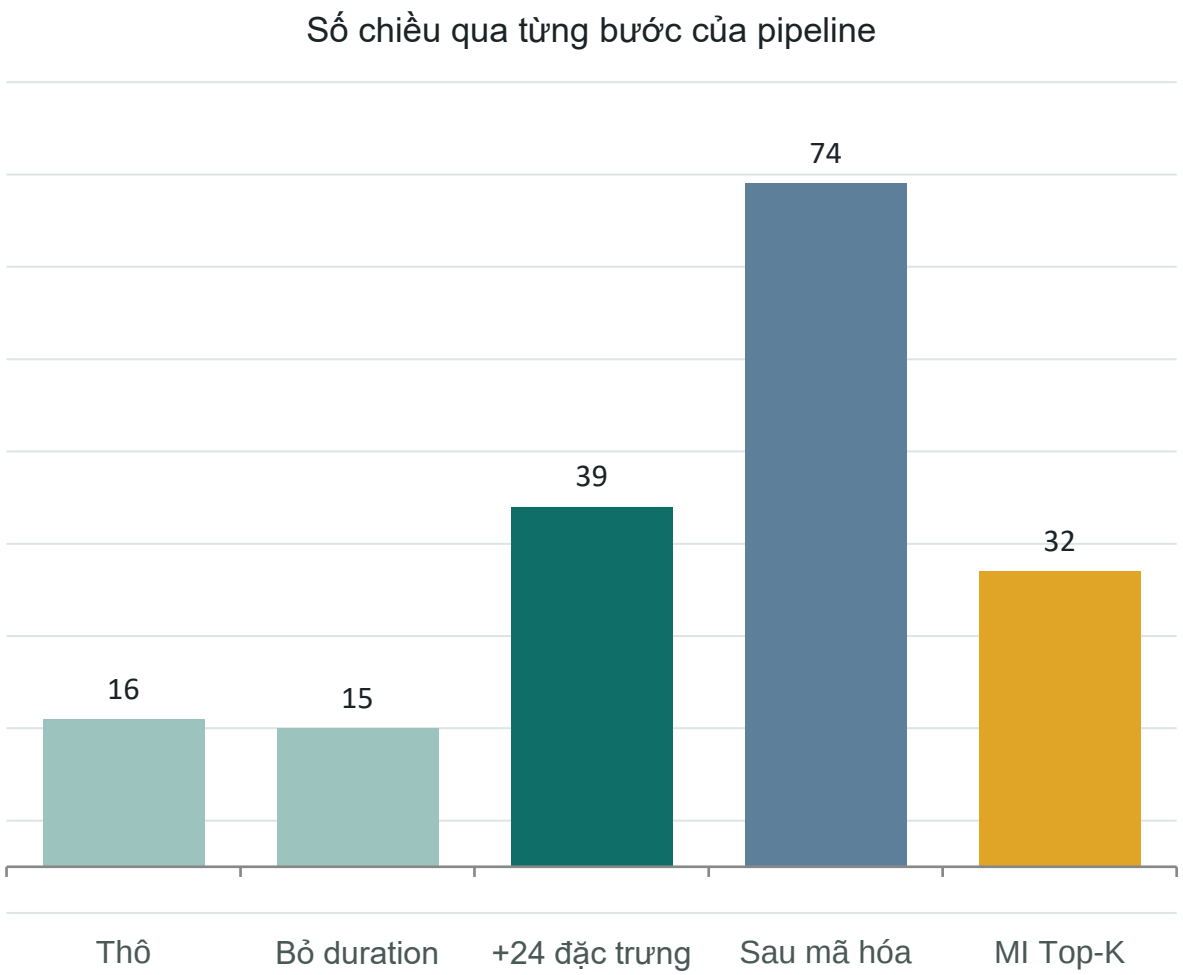
Mọi tham số học từ Train

Median, ngưỡng IQR, scaler, điểm Mutual Information

Đã kiểm chứng

transform(X_test thô) trùng khớp X_test.parquet đã lưu

Biến đổi đặc trưng: 16 → 15 → 39 → 74 → 32



Đặc trưng mới tiêu biểu

age_squared
Quan hệ cong theo tuổi (trẻ & già đăng ký nhiều)

balance_positive_log
Giảm đuôi phải của số dư

prior_contacted
Tách mã pdays = −1 thành cờ 0/1

contact_month_sin/cos
Biểu diễn tháng theo chu kỳ

Mã hóa & chọn lọc

- One-Hot (danh nghĩa) · Ordinal (education)
- RobustScaler (biến lệch) · StandardScaler (age, day)
- Mutual Information Top-32, chỉ fit trên Train

Ba họ mô hình và thiết lập Cross-Validation

Logistic Regression

Họ tuyến tính

C = 10 · penalty L1

0.6960

F1-macro CV (5 fold)

Random Forest

Họ cây / Ensemble

300 cây · max_depth 20
min_samples_split 10

0.7233

F1-macro CV (5 fold)

SVC (kernel RBF)

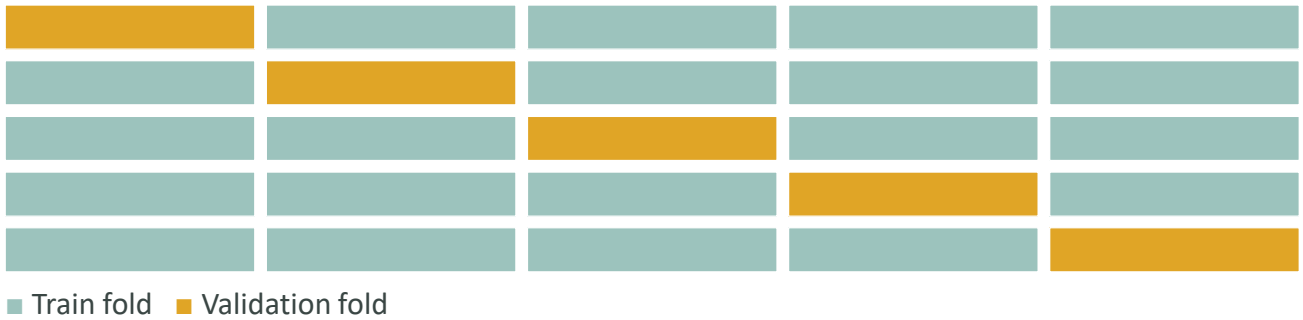
Họ phi tuyến (kernel)

C = 100 · γ = 0.01

0.7178

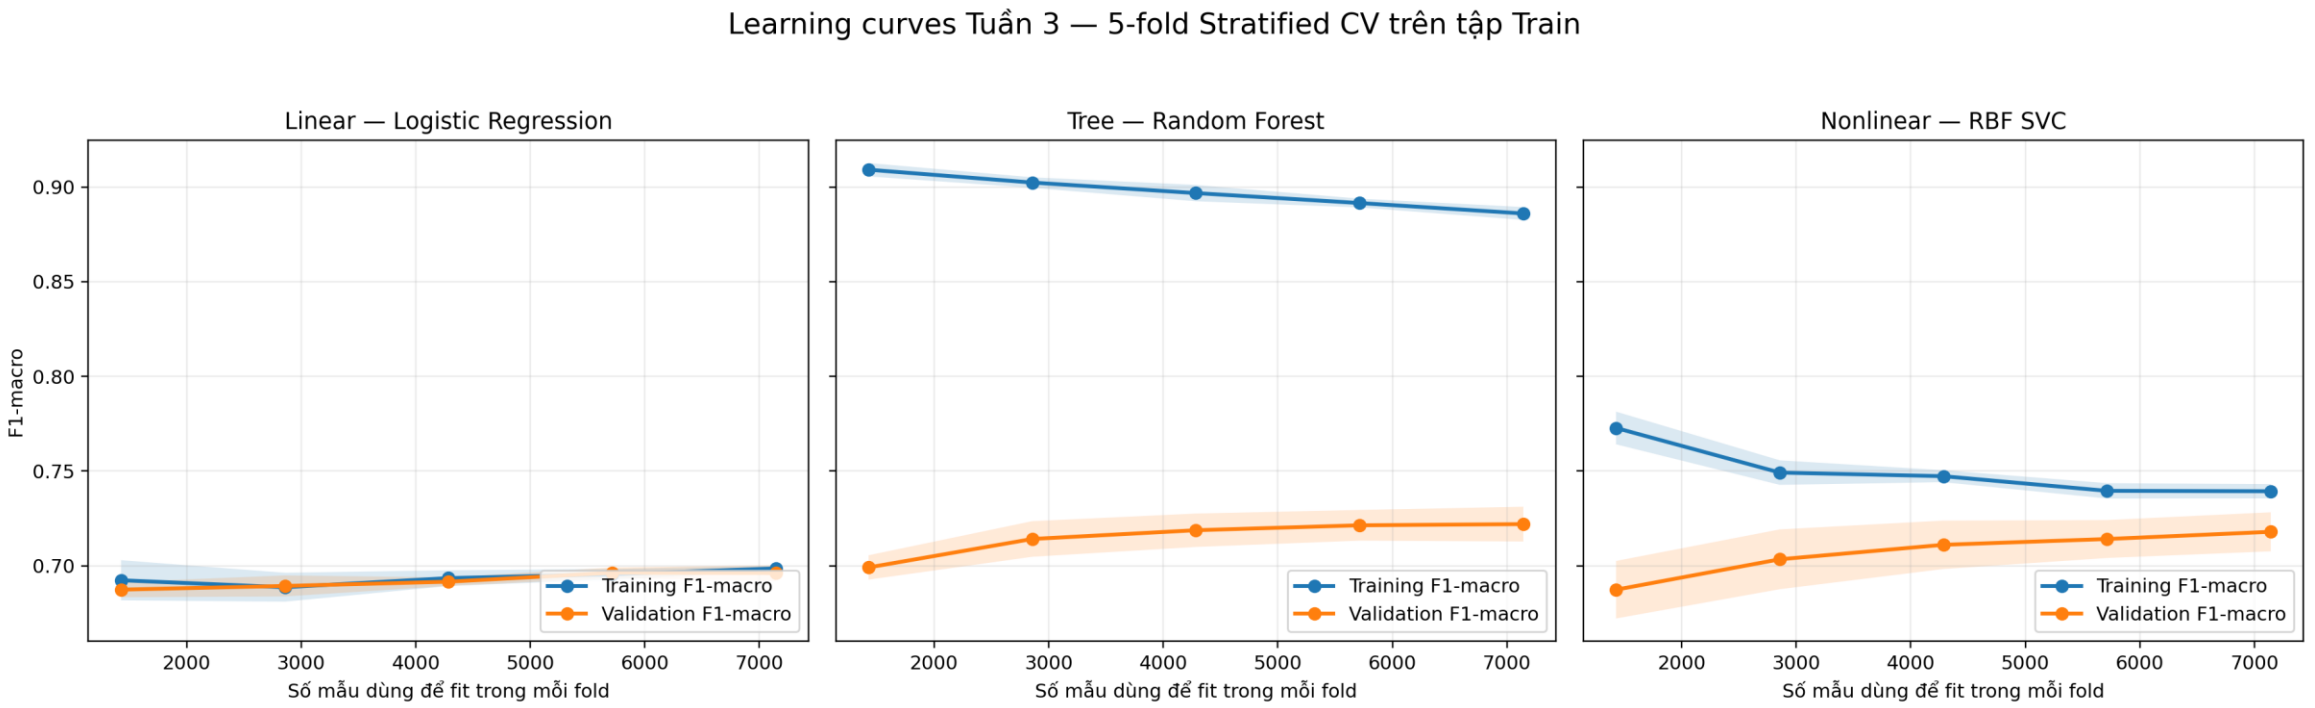
F1-macro CV (5 fold)

StratifiedKFold(5); preprocessing/MI đã fit toàn Train trước CV



- GridSearch + F1-macro (CV có giới hạn)
- Chỉ trên Train (8,929 mẫu)
- Test bị khóa đến Tuần 4
- Mốc dưới: Dummy = 0.3448

Learning curves: chẩn đoán bias và variance



Gap 0.002 **Logistic Regression**

Bias cao — hai đường sát nhau ở mức thấp

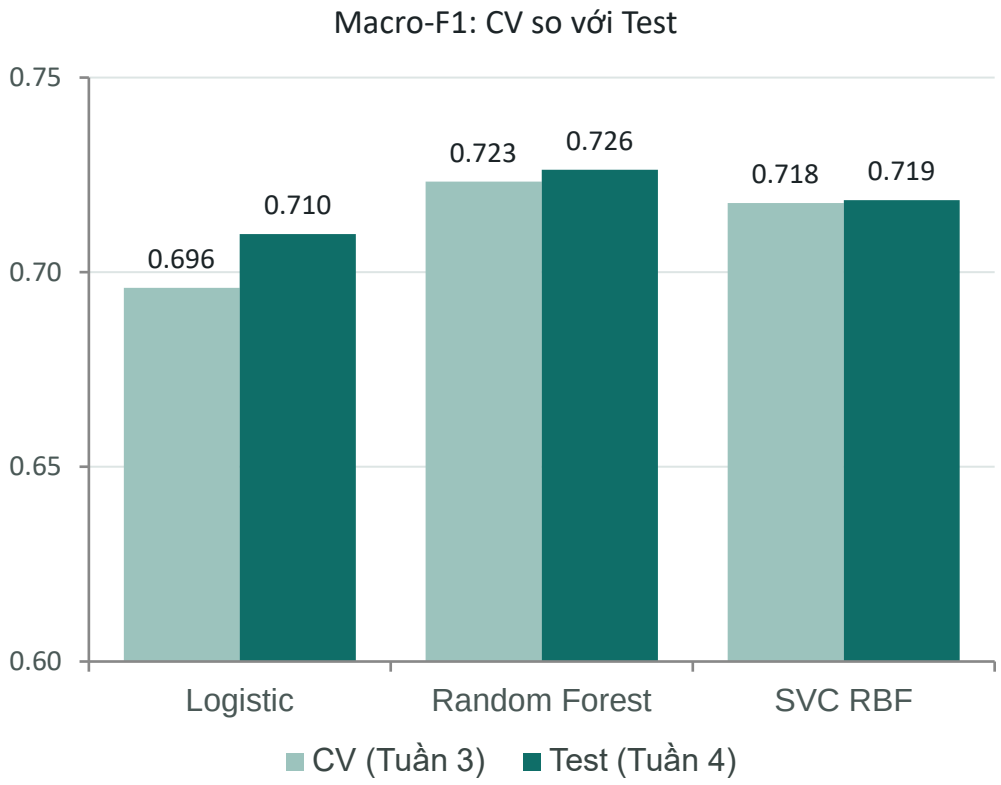
Gap 0.164 **Random Forest**

Variance cao — train 0.886 vs validation 0.722

Gap 0.021 **SVC RBF**

Cân bằng — validation còn tăng khi thêm dữ liệu

Kết quả trên tập Test độc lập (2,233 mẫu)



Mô hình	Macro-F1	Precision	Recall	ROC-AUC	AP
Logistic	0.7098	73.8%	61.6%	0.7605	0.7654
Random Forest	**0.7263**	76.3%	**62.9%**	**0.7747**	**0.7774**
SVC RBF	0.7185	**78.4%**	58.5%	0.7729	0.7727
Dummy	0.3448	0%	0%	0.5000	0.4738

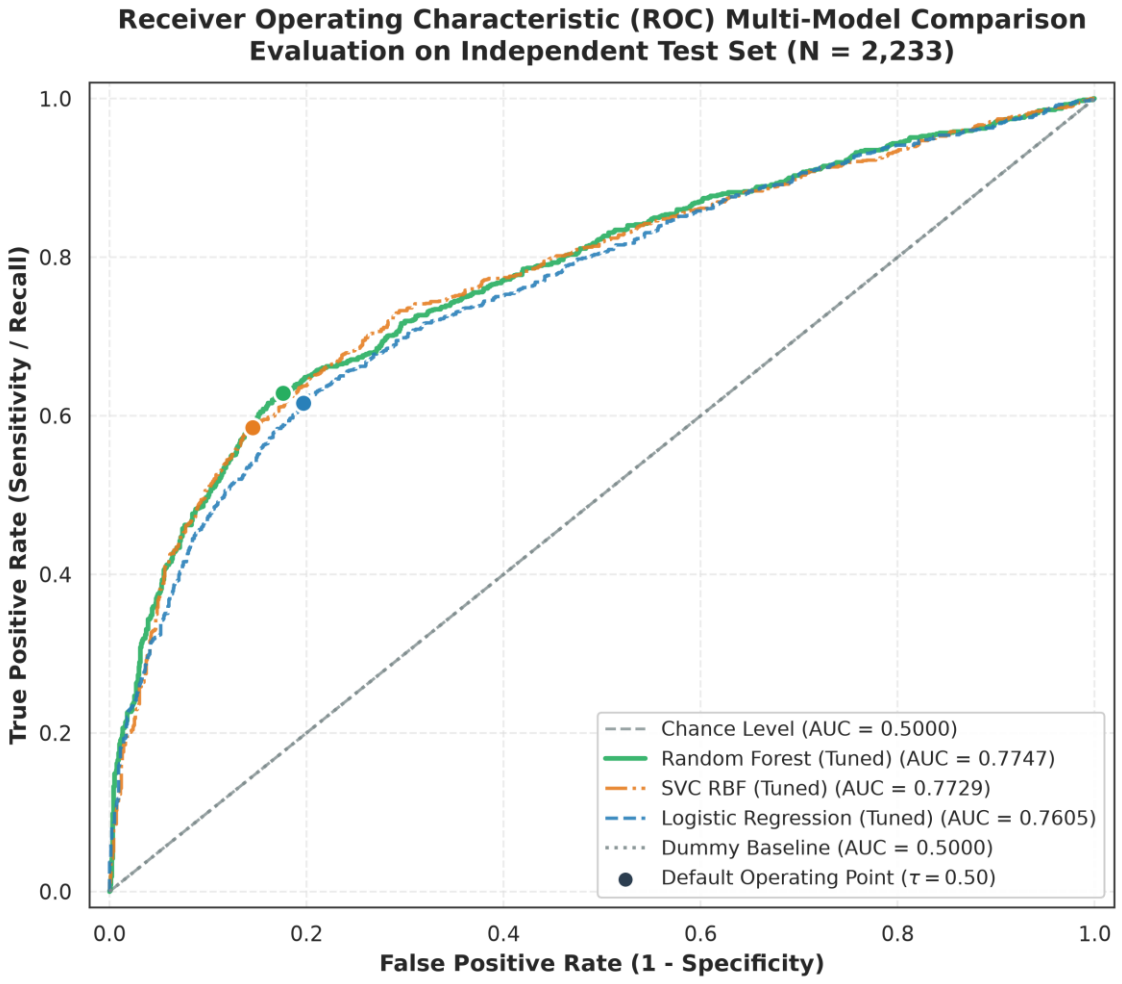
Lớp yes; model.predict (SVC: margin 0). AP = AP. Ô xanh = lớn nhất.

Gap CV – Test nhỏ không loại trừ overfit · Dummy 0.345

Vì sao Macro-F1 là chỉ số chính?

Trọng số bằng nhau cho 'yes' và 'no' — Accuracy che giấu việc bỏ sót khách 'yes' (Dummy: Accuracy 52.6%, Recall 0)

Đường ROC và minh họa đánh đổi ngưỡng



Ngưỡng phải chọn trên validation

MẶC ĐỊNH · Random Forest, τ = 0.50

Precision 76.3% · Recall 62.9%

A · Ngân sách gọi ít → ưu tiên Precision

SVC margin 0: Precision 78.4% trên Test; điểm không phải xác suất

B · Minh họa hậu nghiệm trên Test

τ ≈ 0.41 chỉ minh họa, chưa triển khai: **Recall 62.9% → 71.9%**, Precision 76.3% → 68.4%

Ma trận đánh đổi: không mô hình nào thắng tất cả

Tiêu chí	Logistic Regression	Random Forest	SVC RBF
Macro-F1 (Test)	0.7098	**0.7263**	0.7185
Recall lớp 'yes'	61.6%	**62.9%**	58.5%
Precision lớp 'yes'	73.8%	76.3%	**78.4%**
Độ trễ 1 mẫu (median)	**0.55 ms**	28.38 ms	0.91 ms
Throughput batch	**3.39 triệu mẫu/s**	44.36 nghìn mẫu/s	3.09 nghìn mẫu/s
Kích thước file	**0.003 MB**	41.5 MB	1.5 MB
Khả năng giải thích	**Cao — hệ số có dấu**	Trung bình — feature importance	Thấp — support vectors

Tốt nhất Kém nhất

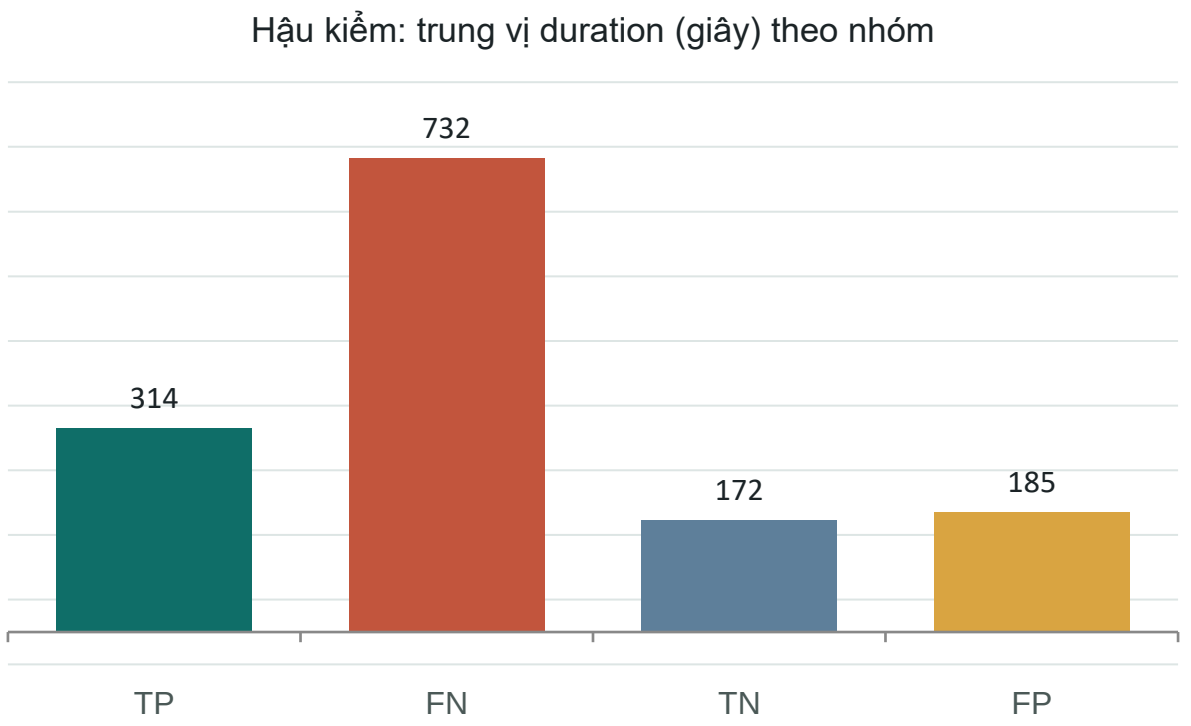
Model-only predict; bản ghi c0ae203. Batch ưu tiên Macro-F1/Recall; chưa có SLA.

Mổ xẻ ca sai và giới hạn dữ liệu quan sát

65% lỗi là FN — bỏ sót khách sẽ đăng ký

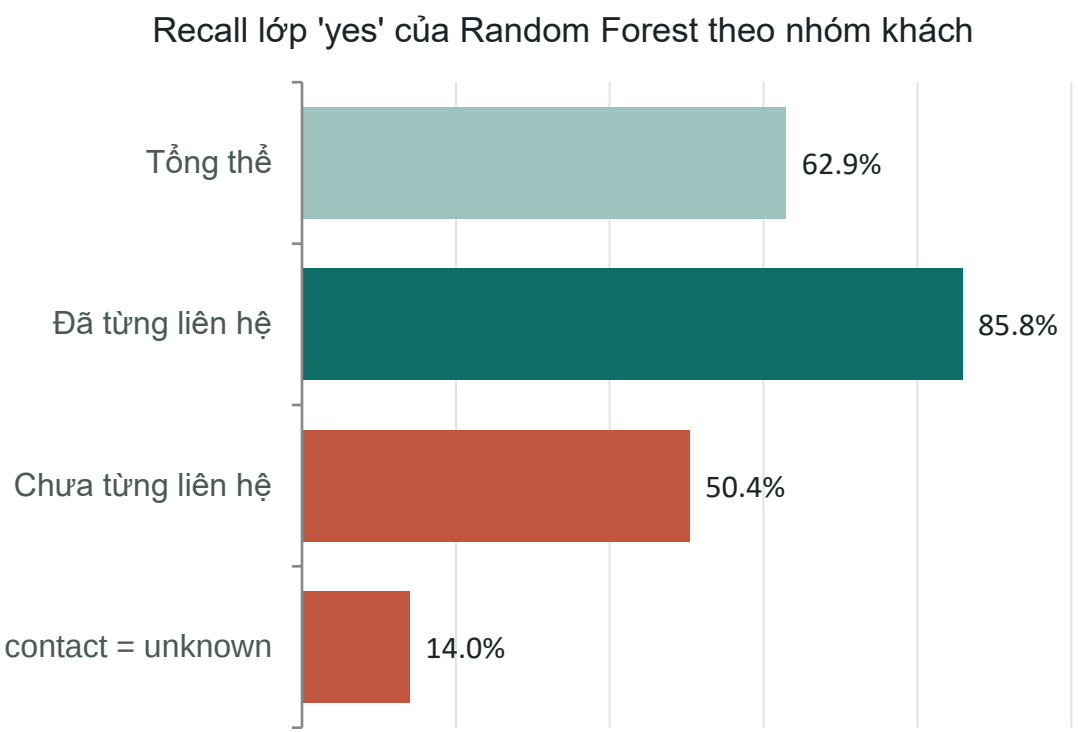
72% lỗi của RF cũng là lỗi của cả 3 mô hình (431/600)

84% lỗi nằm ở vùng chồng lấn lớp: đa số 15 láng giềng Train mang nhãn ngược



FN có duration trung vị cao hơn TP. Chỉ là association; không chứng minh nguyên nhân hay lỗi không thể khử.

Điểm mù dữ liệu và giới hạn cấu trúc mô hình



contact = unknown: RF bắt 15/107 khách 'yes', Logistic 2/107; association, chưa chứng minh nhân quả

So sánh đối đầu (McNemar)

Cặp	Chỉ A đúng	Chỉ B đúng	p
RF vs Logistic	**174**	137	**0.041 ✓**
RF vs SVC	113	103	0.54 ✗

Tuyến tính: giả thiết cộng tính

Hệ số contact_missing −0.40 luôn kéo xác suất xuống, không biểu diễn được tương tác

Cây: phương sai cao

Sâu 20 tầng → học thuộc vùng thưa (khách đã từng liên hệ, ~25% dữ liệu)

Đề xuất Champion: Random Forest (Tuned)

Bằng chứng trên tập Test

0.7263
Macro-F1 cao nhất

62.9%
Recall 'yes' cao nhất

0.775
ROC-AUC cao nhất

−0.003
Gap CV − Test

Căn cứ thống kê

Thắng Logistic có ý nghĩa

McNemar p = 0.041 < 0.05

Chưa bác bỏ khác biệt với SVC (p = 0.54)

Recall +4.3 điểm %; batch ~14×. McNemar kiểm tra lỗi, không kiểm tra F1.

Đánh đổi chấp nhận

41.5 MB · 28.38 ms/mẫu · chờ xác nhận nhóm

Kết luận và hướng phát triển

Đạt được

- Test tách khỏi fit; CV chưa fold-local
- Cùng split và metric; ghi nhận giới hạn CV
- Random Forest: Macro-F1 0.726 · AUC 0.775
- Phân tích lỗi định lượng, có kiểm định

Hạn chế

- Giới hạn thông tin trước cuộc gọi
- Điểm mù: chưa từng liên hệ, contact = unknown
- Xác suất chưa được hiệu chỉnh (calibration)
- Chưa kiểm tra drift theo thời gian

Hướng phát triển

- Thêm đặc trưng có trước cuộc gọi (giao dịch, thu nhập)
- Chọn ngưỡng theo chi phí FP/FN thực tế
- Hiệu chỉnh xác suất; thử Gradient Boosting
- Giám sát drift và huấn luyện lại định kỳ

Cảm ơn thầy/cô đã lắng nghe — Mời đặt câu hỏi